

Выход формул

1) FLOPS

По условию заданы вход: $1 \times 3 \times 32 \times 32$

Размер после свертки находим по формуле:

$$H_o = \left\lfloor \frac{H_{in} + 2p - k}{s} \right\rfloor + 1$$

k - размер ядра (группа)

p - padding ($p = k/2$)

s - stride - шаг

Получаем (для одного изображения):

Вход	$1 \times 3 \times 32 \times 32$
Conv 7×7	$1 \times 32 \times 16 \times 16$
Max Pool	$1 \times 32 \times 8 \times 8$
Conv 5×5	$1 \times 64 \times 8 \times 8$
Conv 3×3	$1 \times 128 \times 4 \times 4$
Conv 1×1	$1 \times 256 \times 4 \times 4$
Conv 3×3	$1 \times 256 \times 2 \times 2$
Conv 1×1	$1 \times 512 \times 2 \times 2$
Global Pool	1×512
Lin $512 \rightarrow 256$	1×256
Lin $256 \rightarrow 100$	1×100

После каждой свертки
используем ReLU и layer Lin
→ если не указана группа

FLOPS для одного выходного числа:

на первой свертке Conv $7 \times 7 \rightarrow$

$7 \times 7 = 49$ (изучений в одном входном канале)

$49 \times 3 = 147$ MAC (в 3-х каналах)

$147 \times 2 = 294$ FLOPS на одно выходное число

По методу, описанному считаем FLOPS всех слоев ($s=32, b=1$)

$$\text{Conv } 7 \times 7 \quad 3 \times 7 \times 7 \times 32 \times 16 \times 16 \times 2 = 2408448$$

$$\text{Conv } 5 \times 5 \quad 32 \times 5 \times 5 \times 64 \times 8 \times 8 \times 2 = 6553600$$

$$\text{Conv } 3 \times 3 \quad 64 \times 3 \times 3 \times 128 \times 4 \times 4 \times 2 = 2359296$$

$$\text{Conv } 1 \times 1 \quad 128 \times 1 \times 1 \times 256 \times 4 \times 4 \times 2 = 1048576$$

$$\text{Conv } 3 \times 3 \quad 256 \times 3 \times 3 \times 256 \times 2 \times 2 \times 2 = 4718592$$

$$\text{Conv } 1 \times 1 \quad 256 \times 1 \times 1 \times 512 \times 2 \times 2 \times 2 = 1048576$$

$$\text{Lin } 512-256 \quad 512 \times 256 \times 2 = 262144$$

$$\text{Lin } 256-100 \quad 256 \times 100 \times 2 = 51200$$

$$\underline{18450432}$$

FLOPS

(до усреднения и bias)

Для Global Avg Pool у каждого из 512 каналов по 4 значения $\rightarrow$ 3 значения и 1 bias $\rightarrow$ 4 FLOPS

$$\Rightarrow 512 \times 4 = 2048 \text{ FLOPS}$$

У dropout bias = False (глубже задано)

$$\text{Для Lin bias} = \text{True} \Rightarrow 256 + 100 = 356 \text{ значений}$$

ReLU и Max Pool - не зависят - это константа

$$\Rightarrow \text{Для } S=32 \text{ и } B=1:$$

$$18450432 + 2048 + 356 = 18452836 \text{ FLOPS}$$

(System uses aggregate bias checker)

Далее заменим числа на S и B для удобства аналитического выражения:

$$\text{Conv } 7 \times 7 \quad 2 \times B \times 32 \times (S/2)^2 \times 3 \times 7 \times 7 = 2352BS^2$$

$$\text{Conv } 5 \times 5 \quad 2 \times B \times 64 \times (S/4)^2 \times 32 \times 5 \times 5 = 6400BS^2$$

$$\text{Conv } 3 \times 3 \quad 2 \times B \times 128 \times (S/8)^2 \times 64 \times 3 \times 3 = 2304BS^2$$

$$\text{Conv } 1 \times 1 \quad 2 \times B \times 256 \times (S/8)^2 \times 128 = 1024BS^2$$

$$\text{Conv } 3 \times 3 \quad 2 \times B \times 256 \times (S/16)^2 \times 256 \times 3 \times 3 = 4608BS^2$$

$$\text{Conv } 1 \times 1 \quad 2 \times B \times 512 \times (S/16)^2 \times 256 = 1024BS^2$$

$$\underline{17712BS^2}$$

$$\text{Линейная связь дает: } 2 \times B \times 512 \times 256 = 313344B$$

В каждом из 512 каналов перед Global Avg Pool находимся $(S/16)^2$ числа $\Rightarrow 512B(S/16)^2 = 2BS^2$

$$\text{Прибавим bias у 2-х линейных слоев } B(256+100) = 356B$$

$$\Rightarrow F(S, B) = 17712BS^2 + 313344B + 2BS^2 + 356B$$

$$\Rightarrow F(S, B) = 17714BS^2 + 313700B \text{ FLOPS}$$

Проверка: при $S=32$ и $B=1$:

$$17714 \times 1 \times 32 \times 32 + 313700 \times 1 =$$

$$\Rightarrow 18452836 \text{ FLOPS}$$

2) Память (memory)

Одно число FP32 занимает 4 байта

Притом, что исходный входной тензор отсылается на GPU до конца измерения, каждый слой использует результат предыдущего слоя, если используется функция промежуточный результат не удерживается ReLU (inplace = True) не создает отдельную выходную тензора

$$\text{Вход: } 1 \times 3 \times 32 \times 32 \Rightarrow 3072$$

$$\text{В FP32} \Rightarrow 3072 \times 4 = 12288 \text{ байт}$$

$$\text{Первая свертка выдает } 1 \times 32 \times 16 \times 16 \times 4 = 32768$$

Поскольку существует вход и результат свертки:

$$12288 + 32768 = 45056 \text{ байт}$$

$$\text{Следом Max Pool создается тензор } 1 \times 32 \times 8 \times 8 \\ \Rightarrow 8192 \text{ байта}$$

Во время его создания исходный вход остается на GPU, вход свертки еще нужен Max Pool, а новый вход уже выделен:

$$12288 + 32768 + 8192 = 53248 \text{ байт}$$

Следующая свертка Conv 5x5 выдает:

$$1 \times 64 \times 8 \times 8 \times 4 = 16384 \text{ байта}$$

Ей нужен вход Max Pool, но вход Conv 7x7 не нужен

$$\Rightarrow 12288 + 8192 + 16384 = 36864 \text{ байта}$$

После Max Pool размер промежуточных тензоров не превышает больше 24576 байт, а с исходным входом 36864 байт, вход классификационной модели еще меньше. Поэтому суммарная занимаемая память тензоров при $S=32$, $B=1$ приходится на Max Pool и равен 53248 байт

Постоянная память модели

$$\text{Conv } 7 \times 7 \quad 32 \times 3 \times 7 \times 7 = 4704 \text{ параметра}$$

$$\text{Conv } 5 \times 5 \quad 12 \times 2 = 51200$$

$$\text{Conv } 3 \times 3 \quad = 73728$$

$$\text{Conv } 1 \times 1 \quad = 32768$$

$$\text{Conv } 3 \times 3 \quad = 589824$$

$$\text{Conv } 1 \times 1 \quad = 131072$$

$$\text{Lin } 512 \rightarrow 256 \quad 512 \times 256 + 256(\text{bias}) = 131328$$

$$\text{Lin } 256 \rightarrow 100 \quad 256 \times 100 + 100(\text{bias}) = 25700$$

$$\hline 1040324$$

$$1040324 \times 4 (\text{байта}) = 4161296 \text{ байт}$$

Предварительный прогон всего пика для примера:

$$4161296 + 53248 = 4214544 \text{ байт}$$

Для вывода аналитической функции зависимости
числа перемещений S и B

$$\text{Вход } B \times 3 \times S \times S = 3BS^2$$

$$\text{Conv } 7 \times 7 \quad B \times 32 \times (S/2)^2 = 8BS^2$$

$$\text{Вход Max Pool } B \times 32 \times (S/4)^2 = 2BS^2$$

$$\Rightarrow 13BS^2 \times 4 = 52BS^2 \text{ байт}$$

$$\Rightarrow \left| \text{Мемор} \left(\frac{1}{2} S, B \right) = 4161296 + 52BS^2 \text{ байт} \right|$$

Подстановка: при $S=32$ и $B=1$:

$$4161296 + 52 \cdot 32^2 = 4214544 \text{ байт}$$

3) bytes moved - вспомогательная функция $D(S, B)$
- потребляемая при построении Latency (S, B, θ) и
Energy $(S, B, \theta, \text{energy})$

$D(S, B)$ - число данных операции прочитали за
весь проход

Примечание:

FP32 = 4 байта

Каждое Lin и Conv один раз читает свой вход и
два параметра, один раз записывает выход

Max Pool и Global Avg Pool один раз читают вход и
записывают выход

ReLU один раз читает свой тензор и один раз записывает
записывает обратно

Для параметризации θ (bias и bias) описанные
потребностями тензоров за проход

Для Conv 7×7

- чтение входа $1 \times 3 \times 32 \times 32 = 12288 \text{ байт}$

- чтение bias $32 \times 3 \times 7 \times 7 = 18816 \text{ байт}$

- запись выхода $1 \times 32 \times 16 \times 16 = 32768 \text{ байт}$

$$63872 \text{ байт}$$

При задании S и B для Conv 7×7

- число элементов входа - $3BS^2$

- число bias - 4704

- число элементов выхода - $8BS^2$

$$\Rightarrow D_{\text{conv7}}(S, B) = 4(3BS^2 + 4704 + 8BS^2)$$

$$= 44BS^2 + 18816 \text{ байт}$$

$$\text{Для Conv } 5 \times 5 \text{ } D_{\text{conv5}} = 24BS^2 + 204800 \text{ байт}$$

Отдельно Max Pool:

$$\text{bias у него нет} \Rightarrow D_{\text{MaxPool}}(S, B) = 4(8BS^2 + 2BS^2)$$

$$\Rightarrow 40BS^2 \text{ байт}$$

Отдельно для ReLU:

работает inplace, но есть не держит доп. тензор
тензора, но тензор надо прочитать и записать $\Rightarrow$

$$\Rightarrow D_{\text{ReLU}}(S, B) = 4(8BS^2 + 8BS^2) = 64BS^2 \text{ байт}$$

Осложняя 6 слоев, 6 ReLU после слоев, Max Pool и Global Avg Pool получаем:

$$\begin{aligned} 11+6+6+6+5+3 &= 37 BS^2 \\ 2(8+4+2+4+1+2) &= 42 BS^2 \\ 8+2 &= 10 BS^2 \\ 2 BS^2 & \end{aligned}$$

91 BS² умнож
при считывании и
записи из памяти

Добавить задержку (бектрей):

- задержка бектрей Global Avg Pool - 512
- Lin 512-256 (вход и выход) - 512 + 256 = 768
- ReLU задержка (считывание и запись) - 256 + 256 = 512
- Lin 256-100 (вход и выход) - 256 + 100 = 356

2148

=> для данных действительное количество 2148B умнож

Итого: базовые арифметические операции:

$$D(S, B) = 4(91BS^2 + 2148B + 1040324) \text{ байт}$$

4) Latency

Ранее мы считали 2 фреймворка операции об-онг работы
одно прохода:

$$F(S, B) = 17714 BS^2 + 313700B \text{ FLOPS}$$

$$D(S, B) = 4(91BS^2 + 2148B + 1040324) \text{ байт}$$

Введем два параметра GPU

$P > 1$ - эффективная скорость вычисления FLOPS/sec

$W > 1$ - эффективная скорость ввода/вывода данных, байт/сек

$$\Rightarrow T_{\text{выч}}(S, B) = \frac{F(S, B)}{P}$$

$$T_{\text{данных}}(S, B) = \frac{D(S, B)}{W}$$

Вычисление и передача данных могут частично идти
одновременно => ограничение должно минимизироваться
процессом

$$\Rightarrow T_{\text{прод}}(S, B) = \max\left(\frac{F(S, B)}{P}, \frac{D(S, B)}{W}\right)$$

Учтем еще время на загрузку:

$$\Rightarrow \text{Latency}(S, B, Q) = t_0 + \max\left(\frac{F(S, B)}{P}, \frac{D(S, B)}{W}\right)$$

$$\Rightarrow \text{Latency}(S, B, t_0, P, W) = t_0 + \max\left(\frac{17714BS^2 + 313700B}{P}, \frac{4(91BS^2 + 2148B + 1040324)}{W}\right)$$

5) Energy

Потребление энергии базой GPU за
один итерационный проход

Для этого прохода применим 3 слагаемых

- $p_0 \cdot L$ - базовая мощность всей АРЧ за время L
- $e_F \cdot F$ - доп. вклад приложения работы ($\text{Дж}/\text{FLOPS}$)
- $e_D \cdot D$ - доп. вклад обмена данными ($\text{Дж}/\text{байт}$)

$$\Rightarrow E = p_0 L + e_F F + e_D D$$

Для примера $S=32, D=1$ получим:

Ранее нашли: $F(32,1) = 18452836 \text{ FLOPS}$

$$D(32,1) = 4542624 \text{ байт}$$

тогда (на основе предыдущего раздела):

$$L_{32,1} = t_0 + \max\left(\frac{18452836}{P}, \frac{4542624}{W}\right) \text{ сек}$$

тогда энергия этого прохода:

$$E_{32,1} = p_0 \left(t_0 + \max\left(\frac{18452836}{P}, \frac{4542624}{W}\right) \right) + e_F \times 18452836 + e_D \times 4542624$$

Примем t_0, P, W, p_0, e_F, e_D - неизвестно

Используем аналитическую функцию энергии

$$E(S, D, \text{Energy}) = p_0 \left(t_0 + \max\left(\frac{17714BS^2 + 313700B}{P}, \frac{4(91DS^2 + 2148B + 1040324)}{W}\right) \right) + e_F (17714BS^2 + 313700B) + 4e_D (91BS^2 + 2148B + 1040324)$$

t_0, P, W подбираются по измеренной latency

p_0, e_F, e_D подбираются по измеренной энергии