


Leslie N. Smith

U.S. Naval Research Laboratory, Code 5514
4555 Overlook Ave., SW., Washington, D.C. 20375
leslie.smith@nrl.navy.mil

Nicholay Topin

University of Maryland, Baltimore County
Baltimore, MD 21250
ntopin1@umbc.edu

Super-Convergence: Very Fast Training of Neural Networks Using Large Learning Rates Stick



Roman Teterlev

Проблема обучения глубоких нейронных сетей

Стандартным считается длительное обучение с постоянным Learning Rate на каждом этапе и его ступенчатым уменьшением

Обычно:

- Learning Rate сохраняется на уровне 0,1 в течение многих эпох;
- обучение продолжается до выхода тестовой точности на плато;
- затем Learning Rate уменьшается в 10 раз;
- такое снижение повторяется два или три раза;
- в результате обучение занимает десятки тысяч итераций




Можно ли получить такую же или более высокую точность, сократив число итераций примерно на порядок?

Что такое Super-Convergence

Super-Convergence - подход, при котором модель достигает сопоставимой или более высокой тестовой точности за значительно меньшее число итераций.

Ключевой элемент - один цикл изменения Learning Rate с большим максимальным значением



Сравнение стандартного обучения и Super-Convergence для ResNet-56 на CIFAR-10

Особенности:

- примерно на порядок меньше итераций;
- сопоставимая или более высокая точность;
- это эффект специального режима обучения, а не новая архитектура или новый оптимизатор

80 000 итераций → 91,2%

Стандартное обучение

10 000 итераций → 92,4%

Super-Convergence


В эксперименте число итераций сократилось в 8 раз, а тестовая точность выросла

Политика 1cycle


1cycle - политика обучения, при которой Learning Rate проходит один цикл - сначала линейно увеличивается до большого значения, затем уменьшается, а в конце снижается почти до нуля

Изменение Learning Rate и Momentum в политике 1cycle

Схематическое изображение политики 1cycle для режима MNIST-LeNet на 12 эпох



Learning Rate в конце эпохи: $0,01 \rightarrow 0,1 \rightarrow 0,01 \rightarrow \sim 0$



Momentum в конце эпохи: $0,95 \rightarrow 0,8 \rightarrow 0,95$


Пояснение:

- первые 5 эпох Learning Rate растет, Momentum снижается;
- следующие 5 эпох Learning Rate снижается, Momentum растет;
- последние 2 эпохи Learning Rate дополнительно снижается почти до нуля


Большой Learning Rate используется только на части обучения.
Последующее снижение помогает модели стабилизироваться около найденного решения

Как выбрать Learning Rate: LR Range Test

LR Range Test - короткий предварительный запуск обучения, во время которого Learning Rate линейно увеличивается от очень малого до заведомо большого значения



Обычный результат: точность растет, достигает максимума и затем снижается. Положение максимума определяет **max_lr**



Точность ResNet-56 остается высокой при Learning Rate до 3. Такое широкое плато указывает на потенциал Super-Convergence


max_lr -
это значение Learning Rate в районе максимальной точности, перед ее заметным снижением

min_lr -
это значение **max_lr**, деленное на 3 или 4

Если точность остается высокой при необычно больших значениях Learning Rate, архитектура может быть пригодна для Super-Convergence

Большой Learning Rate как регуляризация

Большой Learning Rate создает дополнительный шум при обновлении весов и действует как регуляризация: модели сложнее слишком точно подстроиться под обучающие данные



При увеличении Learning Rate примерно от 0,2 до 2,0 ошибка на обучающей выборке растет, а на тестовой выборке - снижается. Модель хуже подстраивается под обучающие примеры, но лучше обобщает новые данные

Как это работает

- при большом Learning Rate веса изменяются крупными шагами;
- большой Learning Rate может помочь избежать узких и острых минимумов;
- обучение может привести к более широкому и плоскому минимуму, который лучше обобщает новые данные

Если большой Learning Rate уже создает сильную регуляризацию, другие ее виды необходимо ослабить:

- уменьшить Weight Decay;
- уменьшить или отключить Dropout;
- подобрать размер батча с учетом общей силы регуляризации

Эксперименты авторов статьи

Авторы проверили Super-Convergence на разных наборах данных, архитектурах и режимах обучения

Набор данных	Архитектуры	Масштаб эксперимента
MNIST	LeNet	Короткое обучение простой сети
CIFAR-10	ResNet-20...110 слоев, Wide ResNet-32, DenseNet-40	Основная серия экспериментов
CIFAR-100	ResNet-56	Более сложная классификация: 100 классов
ImageNet	ResNet-50, Inception-ResNet-v2	1,24 млн изображений и 1000 классов

1. Сравнение режимов обучения

Стандартные схемы изменения Learning Rate сравнивали с циклической политикой CLR, включая 1cycle

2. Глубина сети

Для CIFAR-10 использовали семейство ResNet глубиной от 20 до 110 слоев

3. Объем обучающей выборки

Размер выборки CIFAR-10 уменьшали с 50 000 до 10 000 изображений

4. Размер батча

Проверяли влияние Batch Size на точность и разрыв между точностью на обучающей и тестовой выборках


5. Регуляризация

Изменяли Weight Decay, Dropout и параметры Batch Normalization

Оценивали: точность на тестовой выборке, число эпох и итераций до достижения результата, скорость сходимости и разрыв между точностью на обучающей и тестовой выборках

Основные результаты и выводы статьи

В ключевых экспериментах Super-Convergence сократила число эпох или итераций в 5-10 раз при сопоставимой или более высокой точности



Выводы

Большой Learning Rate выполняет роль регуляризатора
он усиливает шум SGD и способствует поиску широких минимумов

Необходимо сохранять баланс регуляризации
при большом Learning Rate следует уменьшать Weight Decay и другие виды регуляризации

Эффект усиливается при недостатке данных
на 10 000 изображений CIFAR-10 прирост составил 9,2 процентного пункта, а на полном наборе данных только 1,2 процентного пункта

Количественные результаты

CIFAR-10, ResNet-56

- стандартное обучение: 91,2% за 80 000 итераций
 - Super-Convergence: 92,4% за 10 000 итераций
- в 8 раз меньше итераций и +1,2 п.п.

MNIST, LeNet

- стандартное обучение: $99,03 \pm 0,04\%$ за 85 эпох
 - 1cycle: $99,25 \pm 0,03\%$ за 12 эпох
- примерно в 7 раз меньше эпох

CIFAR-100, ResNet-56

- стандартное обучение: $61,6 \pm 0,9\%$ за 200 эпох
 - 1cycle: $65,4 \pm 0,2\%$ за 25 эпох
- в 8 раз меньше эпох и +3,8 п.п.

ImageNet

- ResNet-50: 63,7% за 100 эпох против 67,6% за 20 эпох
 - Inception-ResNet-v2: 67,6% за 100 эпох против 74,0% за 20 эпох
- в 5 раз меньше эпох

Ограничения

Эффект не возникает автоматически.
Диапазон Learning Rate и силу регуляризации необходимо подбирать для каждого набора данных и архитектуры

В дополнительных экспериментах авторы не получили Super-Convergence с Adam.
Кривые для ImageNet усреднены только по двум запускам